

Plano de Trabalho de Conclusão de Curso

Otimização na seleção de portfólios de investimento utilizando meta-heurística evolutiva e rede neural artificial

UDESC – Centro de Ciências Tecnológicas

Departamento de Ciência da Computação
Bacharelado em Ciência da Computação
Turma 2020/1 – Joinville/SC

Paula Campigotto - paula_campigotto@hotmail.com
Omair Correia Alves Junior - omir.alves@udesc.br (*orientador*)

16 de março de 2020

Resumo

A seleção de um portfólio de investimento pode ser classificada como um problema combinatorial multiobjetivo, posto que pretende reduzir o risco de perda e potencializar o retorno esperado. Por demandar um custo computacional impraticável no uso de métodos matemáticos exatos, as principais técnicas utilizadas para a solução deste problema são as meta-heurísticas, as quais fornecem um resultado aproximativo. No entanto, existem outras maneiras de selecionar um portfólio ou refinar tal seleção, como o uso de redes neurais artificiais, uma modelagem que não é tão explorada na otimização de portfólios como as meta-heurísticas. Desta forma, este trabalho pretende comparar a rentabilidade das soluções geradas por um método meta-heurístico e por um modelo que faz uso de redes neurais artificiais.

Palavras-chave: *Portfólios de investimento, Otimização multiobjetivo, Redes neurais artificiais, Meta-heurísticas.*

1 Introdução e Justificativa

A seleção de um portfólio, ou carteira, de investimentos consiste na combinação de diversos ativos, tais como ações, moedas, *commodities*, títulos públicos ou debêntures, que podem variar de acordo com o perfil do investidor. As principais máximas utilizadas na seleção em otimização de portfólio são a minimização do risco de perda e a maximização do retorno esperado, isto é, espera-se que todo investidor tenha esses dois objetivos a serem alcançados ao realizar um investimento no mercado financeiro.

Partindo desses pressupostos, Markowitz (1952) formulou a Teoria Moderna de Portfólios, que contextualiza o seu problema de otimização, também conhecido como modelo de variância média,

o qual objetiva estimar a proporção de ativos que comporão uma carteira de investimentos. Tal modelo recebeu este nome, variância média, por utilizar a variância do portfólio como métrica para o cálculo do risco pelo qual este portfólio está exposto. Harry Markowitz formulou matematicamente seu problema utilizando uma função multiobjetivo, conforme as Equações 1 e 2, sujeitas às restrições apresentadas nas Equações 3 e 4.

$$\min \sum_{i=1}^N \sum_{j=1}^N w_i w_j \sigma_{ij} \quad (1)$$

$$\max \sum_{i=1}^N w_i \mu_i = R \quad (2)$$

$$\sum_{i=1}^N w_i = 1 \quad (3)$$

$$0 \leq w_i, w_j \leq 1, \quad i, j = 1, \dots, N \quad (4)$$

Na Equação 1 é apresentada a função objetivo que visa a minimização do risco e que é dada pelo somatório da covariância σ_{ij} de todos os pares i e j de ativos da carteira, composta por N ativos, multiplicada pelas proporções desses ativos. A covariância σ_{ij} é exposta na Equação 5, em que o valor de T corresponde ao número total de cotações utilizadas. Cada uma dessas cotações pode ser identificada por seu tempo t , sendo $t \in \{1, 2, \dots, T\}$. O valor de r_i^t é a taxa de retorno do ativo i no tempo t e pode ser visualizada na Equação 6. Por fim, μ_i equivale ao retorno esperado do ativo i .

$$\sigma_{ij} = \frac{1}{T} \sum_{t=1}^T (r_i^t - \mu_i)(r_j^t - \mu_j) \quad (5)$$

$$r_t = \frac{p_t - p_{t-1}}{p_{t-1}} \quad p_t = \text{preço do ativo no tempo } t \quad (6)$$

A segunda função objetivo do problema diz respeito à maximização do retorno R , apresentado na Equação 2, e corresponde ao somatório do produto entre a proporção, ou peso, w_i e o retorno esperado μ_i de cada ativo i . As restrições impostas pelo problema garantem que o somatório de todas as proporções dos ativos integrantes da carteira sejam igual a 1 (Equação 3) e que as proporções de cada um dos ativos estejam compreendidas no intervalo $[0, 1]$ (Equação 4).

Há outras maneiras para mensurar o risco em portfólios de investimentos, como por exemplo a utilização das métricas *Value at Risk* – VaR (JORION,) e *Conditional Value at Risk* – $CVaR$ (ROCKAFELLAR; URYASEV, 2000), os quais são métodos estatísticos e realizam a ordenação dos retornos do portfólio a fim de encontrar o valor do risco utilizando um nível de confiança $\beta \in (0, 1)$ e o número n correspondente ao tamanho da série histórica dos ativos. O VaR corresponde ao valor da perda na posição $(1 - \beta)n$ da série ordenada, todavia, Rockafellar e Uryasev (2002) propuseram o $CVaR$, o qual considera perdas maiores do que o índice do VaR , solucionando este problema que estava presente no cálculo do risco com VaR .

Rockafellar e Uryasev (2000) definiram a fórmula do VaR conforme a Equação 7, em que x é o portfólio em questão, β representa o nível de confiança e $\alpha_\beta(x)$ é o menor valor para α quando $\Psi(x, \alpha) = \beta$. A função $\Psi(x, \alpha)$ pode ser visualizada na Equação 8, onde x representa o vetor de pesos de ativos em um portfólio, e y é um vetor de incertezas, isto é, a série de perdas ou parâmetros de mercado que podem influenciar a perda, e $p(y)$ é a distribuição de probabilidade de y em \mathbb{R} .

Tendo em vista que o retorno de um portfólio é calculado a partir da soma do retorno de todos os ativos multiplicados por suas respectivas proporções, é possível afirmar que a função de perda $f(x, y)$, apresentada na Equação 9, é o oposto do retorno do portfólio. (ROCKAFELLAR; URYASEV, 2000)

$$VaR = \alpha_\beta(x) = \min\{\alpha \in \mathbb{R} : \Psi(x, \alpha) \geq \beta\} \quad (7)$$

$$\Psi(x, \alpha) = \int_{f(x, y) \leq \alpha} p(y) dy \quad (8)$$

$$f(x, y) = -[x_1 y_1 + \dots + x_n y_n] = x^T y \quad (9)$$

Assim, o VaR de um determinado ativo em um portfólio é o número correspondente ao valor $(1 - \beta)n$ dos retornos após serem ordenados e enumerados crescentemente. Dessa forma, é possível afirmar que o VaR corresponde à potencial máxima perda a um intervalo de confiança específico em um tempo determinado e pode ser traduzido como a quantia em que as perdas não se excederão em $(1 - \beta)\%$ dos cenários. (ROCHA, 2013)

O $CVaR$ é a métrica de risco representada pela média das perdas considerando o intervalo entre o pior resultado e o VaR , possibilitando o conhecimento de informações sobre a extensão das perdas. A Equação 10 apresenta o $CVaR$ para distribuição contínua, em que x é o portfólio de ativos, α é o percentil da distribuição de x e $f(x)$ é uma função de perda associada à x . (ARAÚJO; MONTINI, 2015)

Rockafellar e Uryasev (2000) propuseram uma modificação na Equação 10, a qual é apresentada na Equação 11. As variáveis apresentadas são as mesmas mencionadas nas Equações 7, 8 e 9, referentes ao VaR .

$$CVaR_\alpha(X) = -\alpha^{-1} \int_{\infty}^{VaR} x f(x) dx \quad (10)$$

$$\phi_\beta(x) = (1 - \beta)^{-1} \int_{f(x, y) \geq \alpha_\beta(x)} f(x, y) p(y) dy \quad (11)$$

A Equação 12 é uma combinação das Equações 7 e 11, em termos de uma função F_β , para distribuições contínuas de probabilidade. Para distribuições discretas, há algumas modificações na

fórmula, conforme (ARAÚJO; MONTINI, 2015), apresentadas na Equação 13.

$$F_{\beta}(x, \alpha) = \alpha + (1 - \beta)^{-1} \int_{y \in \mathbb{R}^m} [f(x, y) - \alpha]^+ p(y) dy \quad (12)$$


$$F'_{\beta}(x, \alpha) = \alpha + \frac{1}{n(1 - \beta)} \sum_{k=1}^n [f(x, y) - \alpha]^+ \quad (13)$$

Dessa forma Araújo e Montini (2015) definem o modelo de otimização de portfólios utilizando o *CVaR* como medida de risco, conforme a Equação 14 e sujeito às restrições apresentadas nas Equações 3 e 4. Por definição, em um específico nível de confiança β , o *VaR* de um portfólio é a menor quantia, α , tal que, com uma probabilidade $\beta \in \{0.90, 0.95, 0.99\}$, a perda não excederá α . O *CVaR* é a expectativa condicional de perdas acima desse valor α . Tais definições garantem que o *VaR* nunca é maior do que o *CVaR*, portanto portfólios com baixo *CVaR* devem ter baixo valor de *VaR*. (ROCKAFELLAR; URYASEV, 2000)

$$Min : \alpha + \frac{1}{n(1 - \beta)} \sum_{i=1}^n [-w_i \mu_i - \alpha]^+ \quad (14)$$

A Figura 1 ilustra a disposição dos retornos de uma carteira de ativos de acordo com a distribuição normal, dessa forma os menores retornos estão mais à esquerda, enquanto que os maiores estão mais à direita.

Figura 1: VaR, CVaR e perda esperada



Fonte: Yamai e Yoshida (2002)

O conflito entre as funções objetivo apresentadas pelas Equações 1 e 2, posto que o retorno de um investimento é proporcional ao seu risco, aumenta a complexidade do problema, impossibilitando

a solução a partir de métodos matemáticos exatos, os quais fornecem o melhor resultado possível. É por este motivo que o problema é chamado multiobjetivo, pois caso tais objetivos não fossem conflitantes seria possível o estabelecimento de uma única função, caracterizando um problema mono-objetivo. Tendo em vista que a composição de um portfólio é dada por n ativos com um peso, ou proporção, $w \in [0, 1]$ cada, e sendo n a cardinalidade da carteira, é intuitiva a noção de que tal otimização trata-se de um problema combinatorial, isto é, a diversificação e a complexidade do problema são proporcionais. Assim, a otimização de portfólios com restrição de cardinalidade está contida na classe computacional de problemas \mathcal{NP} -difícil¹. (DANIELSSON et al., 2001)

O processo de otimização consiste em encontrar a melhor solução para um dado problema, utilizando para isto algoritmos eficientes. Os algoritmos podem ser implementados utilizando-se métodos exatos ou não exatos. As técnicas mais utilizadas quando métodos exatos são impraticáveis, como na otimização de portfólios com restrição de cardinalidade, são as heurísticas e meta-heurísticas, as quais produzem resultados que, apesar de aproximados, têm qualidade aceitável (GOLDBARG; GOLDBARG; LUNA, 2015). As heurísticas são técnicas baseadas em experiência para solucionar problemas, fornecendo uma resposta satisfatória em um tempo computacional razoável. As meta-heurísticas estão em um nível superior às heurísticas, posto que elas guiam o *design* das heurísticas a fim de encontrar, gerar ou selecionar uma heurística (algoritmo de pesquisa parcial) que pode fornecer uma solução suficientemente boa para o problema. Assim os algoritmos meta-heurísticos, ao pesquisar sobre um espaço de busca contendo um conjunto de soluções viáveis, podem encontrar boas soluções com menor esforço computacional, comparado aos métodos baseados em cálculo ou heurísticas simples. (DU; SWAMY, 2016)

Para solucionar certos problemas, a Inteligência Artificial – IA, na qual estão contidas as heurísticas e meta-heurísticas, utiliza e se inspira em diversas técnicas e conceitos observados na natureza, como exemplo os algoritmos *Simulated Annealing*, *Ant Colony*, *Genetic Algorithm*, redes neurais artificiais, dentre outros. Os quais são abstrações das noções de termodinâmica, organização de formigas, biologia evolutiva e sistema nervoso central, respectivamente. A computação explora estes e os demais comportamentos naturais utilizados para resolver problemas e adapta-os para a solução de problemas computacionais e tal ramo da Ciência da Computação é chamado de Computação Natural. (GOEDERT; FILHO; BLANCO, 2017)

A computação evolucionária se baseia no paradigma neo-Darwinista para simular a evolução natural de sistemas biológicos. Tal paradigma é uma combinação da clássica teoria evolucionária de Darwin, da seleção de Weismann e da genética de Mendel. Um algoritmo evolucionário consiste em um gerador e selecionador de população, um estimador de *fitness* e três operadores genéticos básicos chamados de *cruzamento*, *mutação* e *seleção*. Dessa forma indivíduos de uma população competem e trocam informações uns com os outros a partir da geração randômica de uma população inicial que sofrerá iterações de cruzamento e mutações para a geração de novas populações até que um pré-determinado critério seja satisfeito de acordo com o estimador de *fitness*. (DU; SWAMY, 2016)

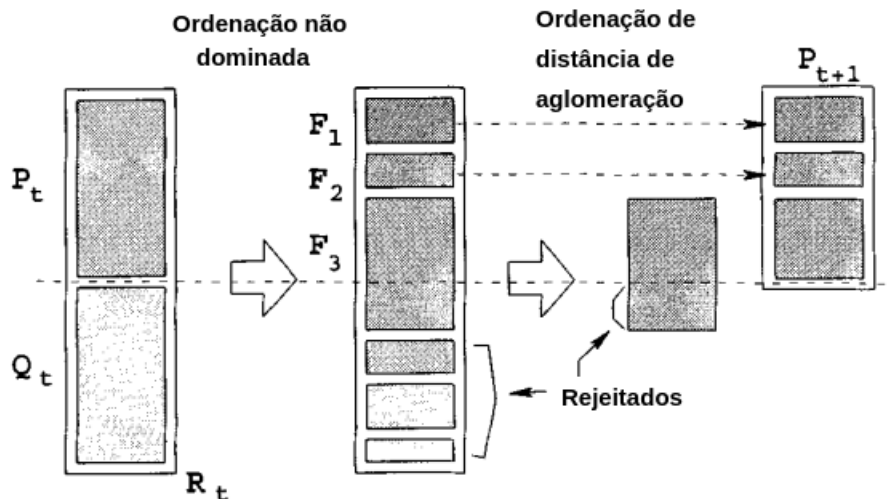
O algoritmo genético é um algoritmo evolutivo e uma de suas ramificações mais utilizadas em

¹Os problemas da classe \mathcal{NP} são aqueles que podem ser solucionados, em tempo polinomial, por uma máquina de Turing não determinística e verificados em tempo polinomial por uma máquina de Turing determinística. (DANIELSSON et al., 2001)

portfólios de investimentos é o *Nondominated Sorting Genetic Algorithm II* – NSGA II, proposto por Deb et al. (2002), o qual é uma evolução de sua primeira versão – NSGA – proposta por Srinivas e Deb (1994). A contribuição do NSGA II sobre o NSGA está em sua complexidade, a qual foi reduzida de $O(N^3m)$ para $O(N^2m)$, em que N é o número de indivíduos e m é o número de funções objetivo.

A Figura 2 ilustra o princípio de funcionamento do NSGA II. Após a criação aleatória da primeira população P_t , de tamanho N , uma nova população, Q_t , também de tamanho N , é gerada a partir das operações de seleção, recombinação e mutação sobre P_t . A união dessas duas populações forma a população $R_t = P_t \cup Q_t$, de tamanho $2N$, a qual será submetida à ordenação de acordo com os critérios de não-dominância². Tal ordenação segregava os indivíduos da população, isto é, associa as soluções à diferentes classes – $F_1, F_2, F_3, \dots, F_n$ – de acordo com o seu elitismo (dominância sobre outras soluções). Dessa forma, os indivíduos pertencentes à classe F_1 são as melhores soluções, as quais estarão presentes, por completo, na população P_{t+1} e quanto maior o índice da classe, piores são as soluções nela contidas. Portanto, para a formação da população P_{t+1} , de tamanho N , são alocados os indivíduos contidos nas primeiras classes enquanto os demais são rejeitados. Por fim, caso P_{t+1} satisfaça o critério de parada, a solução será retornada, caso contrário P_{t+1} atuará como a população inicial da próxima iteração. (DEB et al., 2002)

Figura 2: Processo do NSGA II



Fonte: Deb et al. (2002)

Outra técnica contida no segmento da computação natural é a utilização de redes neurais artificiais, que simulam a transmissão de impulsos nervosos entre os neurônios, os quais são representados por nós em um grafo, que por sua vez representa a rede neural. (SILVA; SPATTI; FLAUZINO, 2016) Os impulsos nervosos são as informações transmitidas entre os nós da rede como entradas e saídas e essa rede pode conter diversas camadas. As camadas de uma rede neural artificial são

²O conceito de não-dominância está relacionado com a fronteira de pareto e as funções objetivo do problema, assim, uma solução domina outra quando seu retorno para a função *fitness*, ou objetivo, é melhor do que o retorno da outra.

definidas pela quantidade de nós que a informação de entrada em outro nó já percorreu, isto é, como as saídas dos neurônios podem ser utilizadas como entradas para outros neurônios pode-se estimar a camada em que o nó pertence através do número de nós pelo qual esta informação já foi uma entrada ou saída. (FACELI et al., 2011)


Os neurônios são as estruturas elementares do sistema nervoso humano e, similarmente, nas redes neurais artificiais, tais estruturas também são chamadas de neurônios, ou nós. Um neurônio artificial consiste em um vetor de múltiplas entradas de valores reais $X = (X_1, \dots, X_r)^T$ e uma única saída Y . Além disso há um vetor $\beta = (\beta_1, \dots, \beta_r)$ o qual compreende os pesos de conexão β_i entre cada entrada e saída. O valor da saída Y é obtida a partir da Equação 15, que utiliza o valor de ativação U , o qual, por sua vez, é a soma de X com seus respectivos pesos presentes no vetor β e está apresentado na Equação 16. (DJEHICHE, 2018)

$$Y = f(U) = f(\beta_0 + X^T \beta) \quad (15)$$

$$U = \beta_0 + \sum_{i=1}^r \beta_i X_i = \beta_0 + X^T \beta \quad (16)$$

Na Equação 15 a função $f(U)$ representa a função de ativação, a qual conecta entradas com a saída de um neurônio. Sua importância está relacionada ao fato de que funções de ativação não lineares são responsáveis por fornecer, às redes neurais artificiais não lineares, a habilidade de modelar funções não lineares e, assim, tais funções podem compactar uma entrada infinita em uma saída finita a partir do mapeamento de \mathbb{R} em um intervalo finito. A Figura 3 apresenta a arquitetura de um neurônio artificial, conforme a explanação referida.

Figura 3: Modelo de neurônio artificial: perceptron com uma única camada



Fonte: Djehiche (2018)

Yaman e Dalkiliç (2019) propuseram um modelo de rede neural artificial para a solução do problema de otimização em portfólios na bolsa de valores de Istambul. A topologia da rede em questão pode ser visualizada na Figura 4 e nas Equações 17, 18 e 19.

O algoritmo representado pela Figura 4 realiza operações sobre os vetores x, y, z, dx, dy e dz considerando a média e o desvio padrão das ações. As entradas dos neurônios da rede neural artificial provêm da saída de outros neurônios, caracterizando a retroalimentação da rede. Por fim,


se os critérios de parada forem atendidos são calculados o retorno esperado, o risco e a razão de Sharpe³ do portfólio selecionado com as proporções de x_i utilizando a Equação 17.

$$x = -2\sigma(x + kx) + [1, 1, \dots, 1]^T(y + ky) + \mu^T(z + kz), x > 0 \quad (17)$$

$$y = [1, 1, \dots, 1] - [1, 1, \dots, 1](x + kx) \quad (18)$$

$$z = -\mu(x + kx) + R, z > 0 \quad (19)$$

Figura 4: Rede neural artificial para otimização de portfólios



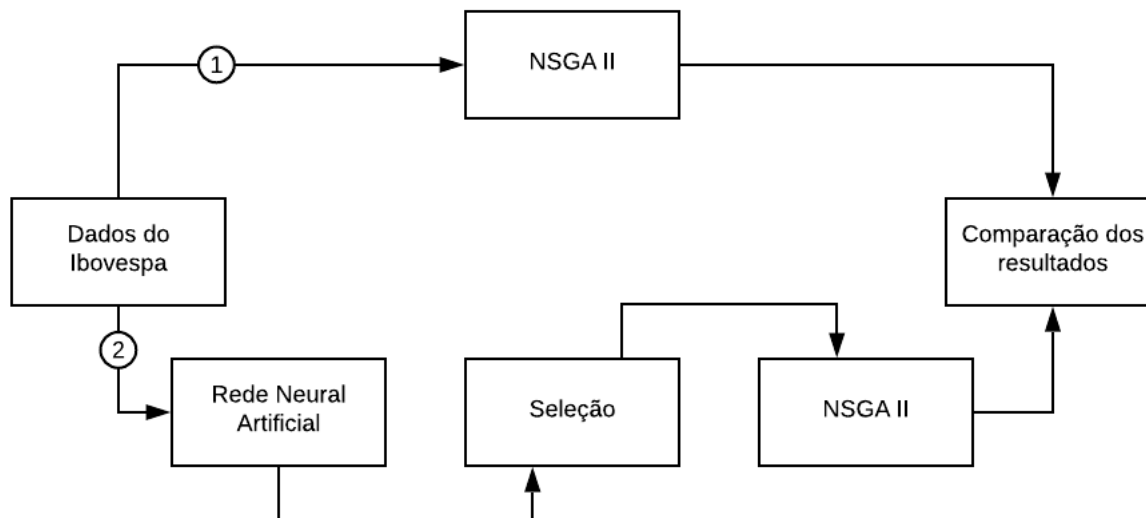
Fonte: Yaman e Dalkiliç (2019)

Cartacho (2001) criou um modelo que utiliza redes neurais artificiais para prever os valores futuros de ativos e um algoritmo genético para a otimização do portfólio. Dessa forma, foi realizada uma simulação de investimentos durante os anos de 1999 e 2000, utilizando carteiras compostas por oito ações negociadas na Bovespa durante o ano referido. O processo foi dividido em duas etapas, na primeira foi utilizado o método de Markowitz para a geração do portfólio e na segunda foi utilizado o modelo híbrido criado pelo autor, o qual utilizou redes neurais e um algoritmo genético. Cartacho (2001) concluiu que os retornos acumulados durante os dois anos de simulação foram de 257,24% para o método tradicional e 419,41% para o modelo alternativo.

Silva (2019) utilizou, em seu trabalho, os modelos de Harry Markowitz e de Black Litterman para realizar a otimização de portfólios. Ademais, o autor também utilizou a técnica de *clusterização* da área de *machine learning* (algoritmo *KMeans*) e comparou os resultados de portfólios calculados em uma única data e portfólios recalculados a cada dois meses. Foi possível concluir que as carteiras geradas pelo modelo Black Litterman foram os mais beneficiados pelo uso da clusterização,

³Uma medida que indica o retorno médio, menos o retorno sem risco, dividido pelo desvio padrão do retorno de um investimento.

Figura 5: Diagrama de processos do experimento



Fonte: Elaborado pela autora (2020)

alcançando um bom desempenho em comparação ao índice *S&P500*.

Dametto (2018) teve como objetivo prever, com maior acurácia, os valores futuros dos ativos presentes na Bovespa, durante oito anos (janeiro de 2010 a dezembro de 2017). Para isso foi comparado e combinado, por meio de ensembles, três técnicas de *machine learning*:

1. Multilayer Perceptrons (MLP)
2. Modelo Auto-regressivo Não-linear com Entradas Exógenas (NARX)
3. Long-Short Term Memory (LSTM)

O ensemble criado obteve precisão de 70%, valor inferior às técnicas MLP e NARX, as quais obtiveram 80% de acurácia, separadamente.

A Figura 5 ilustra os processos a serem realizados neste trabalho. Em primeiro lugar serão colhidos os dados históricos dos valores dos ativos cujas ações compõem o Índice da Bolsa de Valores de São Paulo - Ibovespa durante um período de 5 anos (2015 a 2019). Tais dados serão utilizados para a seleção de um portfólio com determinada cardinalidade. Para isso, serão utilizadas duas técnicas diferentes, a primeira delas, indicada pelo número 1 na Figura 5 utilizará o algoritmo NSGA II para selecionar os ativos e suas devidas proporções. A segunda técnica, indicada pelo número 2 na Figura 5, fará uso de uma rede neural para eleger os melhores ativos, isto é, aqueles que obtiverem o melhor retorno durante a projeção analisada, para que somente depois sejam expostos ao algoritmo NSGA II que indicará quais proporções de cada ativo, gerarão o maior retorno.

As duas carteiras, montadas pelo algoritmo NSGA II e pela RNA com auxílio do NSGA II, terão seus valores comparados entre si e também entre o Índice Bovespa e outros indicadores financeiros como o CDI - Certificado de Depósito Interbancário, a fim de verificar o desempenho obtido pelas técnicas.

Dado o exposto acima, este trabalho de pesquisa tem como objetivo responder a seguinte pergunta: “Qual das técnicas apresentadas é capaz de gerar o portfólio de investimentos de melhor qualidade?”.

2 Objetivos

O trabalho visa, de maneira geral, analisar e comparar o desempenho de dois algoritmos na seleção de um portfólio de investimento, tendo como base de dados a série histórica dos valores dos ativos utilizados. Um dos algoritmos será o NSGA-II, o qual se baseia em heurísticas evolutivas, e o outro será uma modelagem de rede neural, utilizando o conceito de aprendizado de máquina em conjunto com o NSGA-II. Ambos os algoritmos estarão embasados na Teoria Moderna de Portfólios, proposta por Markowitz (1952) e farão uso do modelo de risco CVaR, modelado por Rockafellar e Uryasev (2002).

2.1 Objetivos específicos

- Realizar a revisão bibliográfica dos conceitos utilizados na monografia, tais como: otimização multiobjetivo, portfólios de investimentos, métricas de risco, algoritmos evolutivos e redes neurais artificiais;
- Especificar e implementar um algoritmo de seleção de portfólios utilizando o NSGA-II;
- Especificar e implementar um algoritmo de seleção de portfólios utilizando redes neurais;
- Realizar os testes dos algoritmos com os dados dos ativos coletados
- Analisar os resultados obtidos, comparando com índices financeiros como CDI e Ibovespa;
- Comparar o desempenho dos dois algoritmos propostos, quanto a rentabilidade do portfólio selecionado e ao tempo de execução.

3 Metodologia

Este trabalho de pesquisa empírica realizará uma análise quali-quantitativa dos experimentos realizados de forma indutiva.

A elaboração do trabalho partirá de uma revisão bibliográfica dos principais conceitos abordados na pesquisa, tais como a otimização multiobjetivo, teoria moderna de portfólios, heurísticas e meta-heurísticas evolutivas e redes neurais. Similarmente, será realizada uma revisão de trabalhos relacionados ao tema em questão.

Os dados utilizados na pesquisa serão os valores históricos, diários entre 2015 e 2019, das principais ações contidas na Bolsa de Valores de São Paulo e serão obtidos diretamente no *site* da BM&F Bovespa. Após o tratamento dos dados serão implementados os algoritmos NSGA-II e um modelo de rede neural, os quais fornecerão o possível melhor portfólio de investimento, isto é, que trará melhor rentabilidade. Os algoritmos utilizarão os valores dos 4 primeiros anos (2015 a 2018).

A análise dos resultados será efetuada a partir da verificação do rendimento gerado pelo portfólio selecionado em cada um dos algoritmos no ano de 2019. Tais resultados serão ilustrados em um gráfico de linhas, possibilitando a comparação entre as duas modelagens e também entre outros índices financeiros como o CDI e o Ibovespa. A pesquisa apresentada no trabalho será exploratória e quantitativa, posto que serão realizadas execuções e testes dos algoritmos propostos visando a exploração dos resultados, quantificados, obtidos para a formulação de conclusões sobre o estudo.

A Tabela 1 apresenta o cronograma que a elaboração do trabalho seguirá durante o ano de 2020, sendo o primeiro semestre dedicado ao TCC 1 e o segundo ao TCC 2. A produção do trabalho, de modo geral, está dividida em 8 etapas, as quais estão indicadas abaixo:

1. Elaboração do plano do TCC
2. Revisão bibliográfica
3. Modelagem do problema
4. Escrita do TCC 1
5. Implementação dos algoritmos propostos
6. Execução dos algoritmos implementados
7. Análise dos resultados obtidos
8. Escrita do TCC 2

4 Cronograma proposto

Tabela 1: Cronograma de atividades

Etapas	2020/1						2020/2					
	J	F	M	A	M	J	J	A	S	O	N	D
1												
2												
3												
4												
5												
6												
7												
8												

Fonte: (Elaborado pela autora, 2020)

5 Linha e Grupo de Pesquisa

Este trabalho de conclusão de curso se enquadra na linha de pesquisas de otimização multi-objetivo, meta-heurísticas e aprendizado de máquina. Pertence ao Grupo de Redes e Aplicações Distribuídas (GRADIS), o qual o orientador faz parte.

6 Forma de Acompanhamento/Orientação

O acompanhamento do trabalho se dará a partir de reuniões semanais, na sala do professor orientador, localizada no departamento de Ciência da Computação da UDESC, e caso necessário utilizando meios eletrônicos para o esclarecimento de eventuais dúvidas. O controle da orientação é realizado utilizando uma ata de reunião *online* compartilhada entre a aluna e o orientador, a fim de gerenciar a execução do trabalho.

Referências

ARAÚJO, A. C. de; MONTINI, A. de Á. Análise de métricas de risco na otimização de portfólios de ações. **Revista de Administração**, Business Department, School of Economics, Business & Accounting USP, v. 50, n. 2, p. 208–228, 2015. Disponível em: <<http://www.scielo.br/pdf/rausp/v50n2/0080-2107-rausp-50-02-0208.pdf>>.

ASHWOOD, A. J. **Portfolio selection using Artificial Intelligence**. Tese (Doutorado) — Queensland University of Technology, Brisbane City, jun. 2013.

CARTACHO, A. A. d. S. M. S. **A utilização de um método híbrido algoritmo genético/redes neurais no processo de seleção de carteiras**. Belo Horizonte, 2001. Disponível em: <<https://repositorio.ufmg.br/handle/1843/BUBD-99UHEK>>.

CASTILHO, D. et al. Improving portfolio optimization using weighted link prediction in dynamic stock networks. In: **Lecture Notes in Computer Science**. Springer International Publishing, 2019. p. 340–353. Disponível em: <https://doi.org/10.1007/978-3-030-22744-9_27>.

COELLO, C. C. Evolutionary multi-objective optimization: a historical view of the field. **IEEE Computational Intelligence Magazine**, Institute of Electrical and Electronics Engineers (IEEE), v. 1, n. 1, p. 28–36, fev. 2006. Disponível em: <<https://doi.org/10.1109/mci.2006.1597059>>.

DAMETTO, R. C. **Estudo da aplicação de redes neurais artificiais para predição de séries temporais financeiras**. Bauru, 2018. Disponível em: <<https://repositorio.unesp.br/handle/11449/157058?locale-attribute=en>>.

DANIELSSON, J. et al. Optimal portfolio allocation under a probabilistic risk constraint and the incentives for financial innovation. **Tinbergen Institute**, Tinbergen Institute, 2001. Disponível em: <<https://papers.tinbergen.nl/01069.pdf>>.

DEB, K. et al. A fast and elitist multiobjective genetic algorithm: NSGA-II. **IEEE Transactions on Evolutionary Computation**, Institute of Electrical and Electronics Engineers (IEEE), v. 6, n. 2, p. 182–197, abr. 2002. Disponível em: <<https://doi.org/10.1109/4235.996017>>.

DJEHICHE, Y. A neural networks approach to portfolio choice. **Royal Institute of Technology: School of Engineering Sciences**, 2018. Disponível em: <<https://pdfs.semanticscholar.org/dc1d/e4407ddf45071a85b00f121abdb23375aa1a.pdf>>.

DU, K.-L.; SWAMY, M. N. S. **Search and Optimization by Metaheuristics**. Springer International Publishing, 2016. Disponível em: <<https://doi.org/10.1007/978-3-319-41192-7>>.

FACELI, K. et al. **Inteligência Artificial. Uma Abordagem de Aprendizado de Máquina**. Rio de Janeiro: LTC, 2011.

FERREIRA, F. G. D. C.; BARROSO, B. C.; CARDOSO, R. T. N. Comparação de algoritmos meta-heurísticos para otimização combinatória multiobjetivo de portfólios financeiros. **XLIX Simpósio Brasileiro de Pesquisa Operacional**, ago. 2017. Disponível em: <<http://www.sbp2017.iltc.br/pdf/168602.pdf>>.

FREITAS, F. D. de et al. Portfolio selection with predicted returns using neural networks. **Universidade Federal do Espírito Santo**, Universidade Federal do Espírito Santo, 2003. Disponível em: <http://www.inf.ufes.br/~alberto/papers/aia2001_348-101.pdf>.

GOEDERT, M. L.; FILHO, P. L. P.; BLANCO, D. R. Natural computing: concepts and applications of computing inspired by nature. **Espacios**, v. 38, n. 34, p. 31–46, Mar 2017. Disponível em: <<https://www.revistaespacios.com/a17v38n34/a17v38n34p31.pdf>>.

GOLDBARG, M. C.; GOLDBARG, E.; LUNA, H. P. L. **Otimização Combinatória e Metaheurísticas: Algoritmos e Aplicações**. 1. ed. Rio de Janeiro: Elsevier, 2015.

JASZKIEWICZ, A. Genetic local search for multi-objective combinatorial optimization. **European Journal of Operational Research**, Elsevier BV, v. 137, n. 1, p. 50–71, fev. 2002. Disponível em: <[https://doi.org/10.1016/s0377-2217\(01\)00104-7](https://doi.org/10.1016/s0377-2217(01)00104-7)>.

JORION, P. **Value at Risk: The New Benchmark for Managing Financial Risk**. [S.l.]: McGraw-Hill Education.

KOLM, P. N.; TÛTÛNCÛ, R.; FABOZZI, F. J. 60 years of portfolio optimization: Practical challenges and current trends. **European Journal of Operational Research**, Elsevier BV, v. 234, n. 2, p. 356–371, abr. 2014. Disponível em: <<https://doi.org/10.1016/j.ejor.2013.10.060>>.

MAINDONALD, J. Modern multivariate statistical techniques: Regression, classification and manifold learning. **Journal of Statistical Software**, Foundation for Open Access Statistics, v. 29, n. Book Review 11, 2009. Disponível em: <<https://doi.org/10.18637/jss.v029.b11>>.

MANSINI, R.; OGRYCZAK, W.; SPERANZA, M. G. **Linear and Mixed Integer Programming for Portfolio Optimization**. Springer International Publishing, 2015. Disponível em: <<https://doi.org/10.1007/978-3-319-18482-1>>.

MARKOWITZ, H. Portfolio selection. **The Journal of Finance**, Wiley, v. 7, n. 1, p. 77–91, mar. 1952. Disponível em: <<https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>>.

MOREIRA, K. D. S.; PENEDO, A. S. T. Seleção de portfólios: Uma análise comparativa dos cinco fatores de fama e french e redes neurais artificiais. **Enfoque: Reflexão Contábil**, Universidade Estadual de Maringá, v. 37, n. 2, p. 141, jun. 2018. Disponível em: <<https://doi.org/10.4025/enfoque.v37i2.38329>>.

ROCHA, J. E. N. D. **Sistema Inteligente de Diagnósticos Energéticos e de Análise de Investimentos em Projetos de Eficiência Energética Gerenciados pelo Lado da Demanda**. Tese (Doutorado) — Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, abr. 2013.

ROCKAFELLAR, R.; URYASEV, S. Conditional value-at-risk for general loss distributions. **Journal of Banking & Finance**, Elsevier BV, v. 26, n. 7, p. 1443–1471, jul. 2002. Disponível em: <[https://doi.org/10.1016/s0378-4266\(02\)00271-6](https://doi.org/10.1016/s0378-4266(02)00271-6)>.

ROCKAFELLAR, R. T.; URYASEV, S. Optimization of conditional value-at-risk. **The Journal of Risk**, Infopro Digital Services Ltd, v. 2, n. 3, p. 21–41, 2000. Disponível em: <<https://doi.org/10.21314/jor.2000.038>>.

SILVA, I. N. da; SPATTI, D. H.; FLAUZINO, R. A. **Redes Neurais Artificiais Para Engenharia e Ciencias Aplicadas: Fundamentos Teoricos e Aspectos Praticos**. 2. ed. São Paulo: Artliber, 2016.

SILVA, N. Q. M. da. **Otimização de portfólios de investimentos baseada em aprendizado não-supervisionado**. Rio de Janeiro, 2019. Disponível em: <<http://monografias.poli.ufrj.br/monografias/monopoli10028312.pdf>>.

SRINIVAS, N.; DEB, K. Multiobjective optimization using nondominated sorting in genetic algorithms. **Evolutionary Computation**, Indian Institute of Technology, 1994. Disponível em: <https://web.njit.edu/~horacio/Math451H/download/SrinivasDeb_GA.pdf>.

YAMAI, Y.; YOSHIBA, T. Comparative analyses of expected shortfall and value-at-risk: Their estimation error, decomposition, and optimization. **Econ Papers**, 2002. Disponível em: <https://econpapers.repec.org/article/imeimemes/v_3a20_3ay_3a2002_3ai_3a1_3ap_3a87-121.htm>.

YAMAN, I.; DALKILIÇ, T. E. Portfolio selection based on a nonlinear neural network: An application on the istanbul stock exchange (ISE30). **Communications Faculty Of Science University of Ankara Series A1 Mathematics and Statistics**, Communications Faculty of Sciences University of Ankara Series A1 Mathematics and Statistics, v. 68, n. 2, p. 1709–1723, jul. 2019. Disponível em: <<https://doi.org/10.31801/cfsuasmas.443670>>.

Omir Correia Alves Junior
(Orientador)

Paula Campigotto
(Aluna)